

DATASET SUMMARY

The Movies Dataset — movies_metadata.csv

Simulasi Industri Junior Data Analyst — Minggu 2, Hari Kamis: Eksplorasi Awal Dataset

1. Ringkasan Dataset

Jumlah Baris	45,466
Jumlah Kolom	24
Baris Duplikat Penuh	17
ID Duplikat	30
Judul Duplikat	3,188
Kolom Bertipe Angka	6 (budget, popularity, revenue, runtime, vote_average, vote_count)
Kolom Bertipe Teks/Kategori	18

2. Screenshot Dataset (5 Baris Pertama)

title	genres	budget	revenue	runtime	vote_average	vote_count	release_date
Toy Story	[{'id': 16, 'name': 'Animation'}	30,000,000	373,554,033	81.0	7.7	5415.0	1995-10-30
Jumanji	[{'id': 12, 'name': 'Adventure'}	65,000,000	262,797,249	104.0	6.9	2413.0	1995-12-15
Grumpier Old Men	[{'id': 10749, 'name': 'Roman	0	0	101.0	6.5	92.0	1995-12-22
Waiting to Exhale	[{'id': 35, 'name': 'Comedy'}	16,000,000	81,452,156	127.0	6.1	34.0	1995-12-22
Father of the Bride Part II	[{'id': 35, 'name': 'Comedy'}	0	76,578,911	106.0	5.7	173.0	1995-02-10

Cuplikan hasil `df.head()` pada kolom-kolom utama dataset `movies_metadata.csv`

3. Statistik Dasar (`df.describe()`)

Statistik	budget	popularity	revenue	runtime	vote_average	vote_count
count	45463.0	45460.0	45460.0	45203.0	45460.0	45460.0
mean	4224578.81	2.92	11209348.54	94.13	5.62	109.9
std	17424132.63	6.01	64332246.74	38.41	1.92	491.31
min	0.0	0.0	0.0	0.0	0.0	0.0
25%	0.0	0.39	0.0	85.0	5.0	3.0
50%	0.0	1.13	0.0	95.0	6.0	10.0
75%	0.0	3.68	0.0	107.0	6.8	34.0
max	380000000.0	547.49	2787965087.0	1256.0	10.0	14075.0

Statistik deskriptif untuk 6 kolom numerik: `budget`, `popularity`, `revenue`, `runtime`, `vote_average`, `vote_count`

4. Jumlah Missing Value

Dari 24 kolom, terdapat **20 kolom** yang memiliki missing value. Kolom dengan missing value terbanyak adalah **belongs_to_collection** (90,12%), **homepage** (82,88%), dan **tagline** (55,10%) — ketiganya wajar karena tidak semua film merupakan bagian dari collection/franchise atau memiliki homepage resmi.


Kolom	Jumlah_Missing	Persentase(%)
belongs_to_collection	40,972	90.12%
homepage	37,684	82.88%
tagline	25,054	55.1%
overview	954	2.1%
poster_path	386	0.85%
runtime	263	0.58%
release_date	87	0.19%
status	87	0.19%
imdb_id	17	0.04%
original_language	11	0.02%
title	6	0.01%
popularity	6	0.01%
vote_average	6	0.01%
video	6	0.01%
revenue	6	0.01%
spoken_languages	6	0.01%
vote_count	6	0.01%
budget	3	0.01%
production_companies	3	0.01%
production_countries	3	0.01%

Tabel jumlah dan persentase missing value per kolom (hanya kolom yang memiliki missing value)

5. Nilai Unik & Kategori

- Kolom **id** memiliki 45,436 nilai unik (hampir seluruhnya unik, sesuai fungsinya sebagai identifier film).
- Kolom **status** memiliki 6 kategori, didominasi oleh **Released** (45,014 film, ±99,2%), sisanya Rumored, Post Production, In Production, Planned, dan Canceled.
- Kolom **original_language** memiliki 92 kategori bahasa berbeda, didominasi Bahasa Inggris (en) sebanyak 32,269 film (±71%), diikuti Prancis (fr) dan Italia (it).
- Kolom **adult** seharusnya hanya berisi True/False, namun ditemukan beberapa baris (indeks 19730, 29503, 35587) yang berisi teks sinopsis — indikasi kesalahan pergeseran kolom (data misalignment) pada baris tersebut.
- Ditemukan 3,188 judul film yang duplikat (kemungkinan remake atau entri ganda), serta 17 baris yang duplikat penuh di seluruh kolom.

6. Visualisasi Eksplorasi Awal



Distribusi bahasa film, status film, runtime, dan boxplot vote_average untuk deteksi outlier awal

7. Outlier Awal (Metode IQR)

Kolom	Batas Atas Wajar (IQR)	Jumlah Outlier	Persentase
budget	0.00	8.890	19,55%
revenue	0.00	7.408	16,30%
runtime	140.00 menit	5.417	11,98%
popularity	8,62	4.236	9,32%
vote_average	9,50	3.603	7,93%
vote_count	80,50	6.889	15,15%

Catatan: budget dan revenue memiliki $Q1=Q3=0$ karena mayoritas data (80,4% dan 83,7%) bernilai 0 — ini bukan outlier sebenarnya, melainkan indikasi **data tidak lengkap/tidak dilaporkan**, bukan variasi alami data.

8. Insight Awal

- Dataset didominasi film berbahasa Inggris dan berstatus Released, sehingga representasi film non-Inggris relatif terbatas untuk analisis lintas bahasa.
- Sebagian besar nilai budget dan revenue adalah 0, menunjukkan data finansial film banyak yang tidak terisi — perlu dibersihkan/di-filter sebelum analisis hubungan budget vs revenue.

- Rata-rata durasi film sekitar 94 menit, dengan sebagian kecil film berdurasi sangat panjang (outlier) yang perlu dicek lebih lanjut (mungkin serial/dokumenter panjang).
- Ditemukan indikasi data rusak (misalignment kolom) pada sejumlah kecil baris — perlu dibersihkan sebelum tahap analisis lanjutan agar tidak mendistorsi hasil.
- Kolom bertipe JSON string (genres, production_companies, spoken_languages, dll) memerlukan proses parsing lebih lanjut sebelum bisa dianalisis secara kategorikal.

Disusun sebagai bagian dari Tugas Hari Kamis — Minggu 2: Data Collection & Understanding