

ANALISIS DATASET FILM

Membersihkan Data 45 Ribuan Film

Sebelum dipakai untuk hitung-hitungan serius, data judul, pemain, cerita, biaya, dan popularitas film ini perlu dirapikan dan dicek dulu.

45K

Judul Film

12
34

Data Angka

abc

Data Kata

Dua Jenis Data dalam Dataset

Setiap film punya kolom berupa angka dan kolom berupa kata



Data Angka (Numerik)

- Durasi film (runtime)
- Tahun / tanggal rilis
- Biaya produksi (budget)
- Pendapatan (revenue)
- Skor & jumlah vote



Data Kata (Teks)

- Judul film
- Ringkasan cerita (overview)
- Bahasa asli film
- Genre (masih format kode)
- Status tayang & link resmi

Waspada: Banyak Nilai “0” yang Menyesatkan

Bukan berarti film-nya gratis — datanya memang tidak diisi

0

BUDGET / REVENUE

hampir di semua baris data terisi angka 0

1

Kenapa bisa 0?

Pengisi data malas / tidak wajib melaporkan angkanya, sehingga sistem otomatis mengisi 0.

2

Bahaya kalau diabaikan

Kalau dipakai langsung untuk hitung rata-rata atau korelasi, hasilnya jadi bias dan salah.

3

Solusi

Nilai 0 pada budget & revenue perlu dianggap data hilang (missing), lalu dibuang atau ditandai sebelum analisis.

Karakteristik Umum Film dalam Dataset

Sebagian besar seragam, tapi satu kolom masih perlu dirapikan



Bahasa Inggris mendominasi

Sebagian besar film memakai bahasa asli / original_language Inggris.



Sudah benar-benar tayang

Status film mayoritas “Released”, bukan rumor atau rencana (rumored/planned).

Genre Masih Berformat Kode

Sebelum:

```
[{"id": 28, "name": "Action"}]
```

Sesudah dirapikan:

Action

Kurung kurawal { } diubah jadi kata biasa yang mudah dibaca dan dianalisis.

Data yang Masih Berantakan

Tiga masalah utama yang ditemukan sebelum data siap dianalisis




Link Website Kosong

Banyak kolom homepage (link resmi film) yang tidak diisi sama sekali.



Cerita “Nyasar”

Ada ringkasan cerita (overview) yang kepanjangan sampai bergeser ke kolom lain.



Film Kembar (Duplikat)

Ada judul film yang tercatat dua kali di dalam dataset yang sama.

Rencana Pembersihan Data

Tiga langkah sebelum data dipakai untuk analisis serius

1

Beresin yang Berantakan

Perbaiki cerita yang nyasar ke kolom lain dan hapus film yang tercatat dua kali (duplikat).

2

Buang Angka 0 yang Salah

Tandai / keluarkan nilai budget dan revenue yang sebenarnya berarti data kosong, bukan 0 asli.

3

Rapikan Kode Genre

Ubah format kode { } pada kolom genre menjadi kata biasa yang mudah dibaca.

Data bersih = kesimpulan akurat 🎬 ✨