

DATASET SUMMARY

Eksplorasi Awal Dataset – movies_metadata.csv (The Movies Dataset) – Simulasi Industri Junior Data Analyst, Minggu 2 (Hari Kamis)

1. Screenshot Dataset (5 Baris Pertama)

title	genres	budget	revenue	release_date	vote_average
Toy Story	[{'id': 16, 'name': 'Animation'}, ...]	30000000	373,554,033	1995-10-30	7.7
Jumanji	[{'id': 12, 'name': 'Adventure'}, ...]	65000000	262,797,249	1995-12-15	6.9
Grumpier Old Men	[{'id': 10749, 'name': 'Romance'}, ...]	0	0	1995-12-22	6.5
Waiting to Exhale	[{'id': 35, 'name': 'Comedy'}, ...]	16000000	81,452,156	1995-12-22	6.1
Father of the Bride Part II	[{'id': 35, 'name': 'Comedy'}]	0	76,578,911	1995-02-10	5.7

*Hasil dari `df.head()`, ditampilkan sebagian kolom karena dataset memiliki 24 kolom.

2. Statistik Dasar (`df.info()` & `df.describe()`)


45.466 Total Baris	24 Total Kolom	4 Kolom Numerik	17 Kolom Duplikat (id)
-----------------------	-------------------	--------------------	---------------------------

Statistik	revenue	runtime	vote_average	vote_count
mean	11.209.350	94,13	5,62	109,90
std	64.332.250	38,41	1,92	491,31
min	0	0	0	0
50% (median)	0	95	6,0	10
max	2.787.965.087	1256	10,0	14.075

3. Missing Value



Total missing value pada seluruh dataset: **105.562 sel**. Kolom dengan missing value terbanyak:

Kolom	Jumlah Missing	Persentase
belongs_to_collection	40.972	90,12%
homepage	37.684	82,88%
tagline	25.054	55,10%
overview	954	2,10%
runtime	263	0,58%
release_date	87	0,19%



4. Jumlah Data Unik & Kategori

- **original_language**: 92 nilai unik – didominasi Bahasa Inggris (en) sebanyak 32.269 film
- **status**: 6 nilai unik (Released, Rumored, Post Production, In Production, Planned, Canceled)
- **adult**: 5 nilai unik (mayoritas False, terdapat sedikit data kotor/anomali)
- **Baris duplikat**: 17 baris | **id duplikat**: 30 baris



5. Outlier Awal

- **Budget = 0** pada 36.573 film (80,4%) – kemungkinan besar data tidak terisi, bukan budget sungguhan Rp0
- **Revenue = 0** pada 38.052 film (83,7%) – pola serupa dengan budget
- **Runtime = 0** pada 1.558 film, dan 108 film memiliki runtime > 300 menit (indikasi outlier/data tidak wajar)
- **Revenue maksimum** mencapai 2.787.965.087 – jauh di atas rata-rata (11 juta), menunjukkan distribusi yang sangat skewed

6. Insight Awal

Dataset movies_metadata.csv secara struktur sudah sesuai dokumentasi (45.466 baris, 24 kolom), namun kualitas datanya perlu diperhatikan sebelum dianalisis lebih lanjut. Kolom seperti *belongs_to_collection* dan *homepage* memiliki missing value sangat tinggi (>80%) sehingga kurang layak dijadikan fitur utama. Sebagian besar film (sekitar 80%) tidak memiliki data budget maupun revenue yang valid (bernilai 0), yang berarti analisis hubungan budget-revenue nantinya harus difilter terlebih dahulu agar hasilnya tidak bias. Mayoritas film berbahasa Inggris (71% dari total), sehingga analisis distribusi bahasa akan didominasi satu kategori. Ditemukan juga baris dan id yang terduplikasi, serta beberapa outlier pada runtime yang perlu dibersihkan pada tahap data cleaning berikutnya.